HW2 KNN

M113040105 劉東霖

壹. compute_distances_two_loops:

一.介紹:利用最簡單的兩個 for 迴圈來算出 train 和 test 用 KNN 在歐基里德距離下算出來的距離,此方法因為要跑雙層 for 迴圈所以花費時間最長。

二. 程式說明:

1. 算距離公式如下圖:

$$d_2(I_1,I_2) = \sqrt{\sum_p \left(I_1^p - I_2^p
ight)^2}$$

- 1. 第1,2個 for 代表有幾個 test 和 train 要跑
- 2. 利用 torch. sqrt(torch. sum((x_test[i]-

x_train[j])**2))

把(第 i 個 test 和第 j 個 train 相減)平方總和,再把結果開根號就是距離矩陣[i,j]的值。

- 3. 算完 num_test*num_train 次後回傳距離矩陣。
- 4. 程式碼如下:

```
num_train = x_train.shape[0]
    num_test = x_test.shape[0]

for i in range(num_test):
    for j in range(num_train):
        dists[j,i]=torch.sqrt(torch.sum((x_test[i]-x_train[j])**2))
```

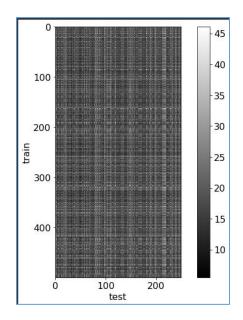
三. 執行結果:

黑。如下圖:

1. 距離矩陣的 shape:

```
torch.manual_seed(0)
num_train = 500
num_test = 250
x_train, y_train, x_test, y_test = data.cifar10(num_train, num_test)
dists = compute_distances_two_loops(x_train, x_test)
print('dists has shape: ', dists.shape)
dists has shape: torch.Size([500, 250])
```

2. 每一個點的距離大小用灰階圖表示,距離越小代表點越

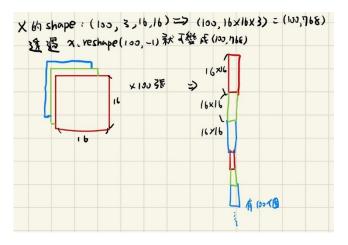


煮. compute_distances_one_loops:

一.介紹:在前一個例子中,因為要用雙層 loop 跑數據,速度非常的慢,所以我嘗試只用一個 loop 跑數據,並利用 broadcast 的方式來計算距離矩陣。

二. 程式說明:

1. 把 test 和 train 資料變成從 4 維變成 2 維,詳情如下圖:



2. 用一個 loop for test 數量,利用下圖程式來用 broadcast 的方式來計算距離矩陣。

dists[:,i]=torch.sqrt(torch.sum((x_test[i,:]-x_train)**2, axis=1))

3. 程式碼:

```
num_train = x_train.shape[0]
num_test = x_test.shape[0]
dists = x_train.new_zeros(num_train, num_test)
```

```
x_train, x_test=x_train.reshape(num_train, -1), x_test.reshape(num_test, -1)
for i in range(num_test):
    dists[:,i]=torch.sqrt(torch.sum((x_test[i,:]-x_train)**2, axis=1))
```

三. 執行結果:

1. 與 two loop 計算時的差異:

Difference: 0.0 Good! The distance matrices match

叁. compute_distances_no_loops:

一. 介紹:no loop 計算將距離的計算方法用多個矩陣相加就可以實現,此方法實現了向量化的方法,大量減少因 loop 所花費的時間。

二. 程式說明:

1. 首先,我們可以把歐基里德距離公式拆解,如下圖所示, II 和 12 分別代表 train 和 test。

$$d_2(\mathbf{I}_1, \mathbf{I}_2) = ||\mathbf{I}_1 - \mathbf{I}_2|| = \sqrt{{||\mathbf{I}_1||}^2 + {||\mathbf{I}_2||}^2 - 2\mathbf{I}_1 \cdot \mathbf{I}_2}$$

- 2. 跟前面一樣,把 train 和 test 從 4 維變 2 維。
- 3. 利用

x_train_square=torch. sum(x_train**2, axis=1, keepdim=True)來計算 x_train 的平方。並把平方完的結果相加。

3. 利用

x_test_square=torch. sum(x_test**2, axis=1)來計算 x_test 的平方。並把平方完的結果相加。

- 4. 利用 cross=torch. matmul(x_train, x_test. T)算出 train 和 test 的內積。
 - 5. 利用 torch. sqrt(x_test_square-

2*cross+x_train_square)

代入1. 圖上的公式,並回傳 dists。

6. 程式碼:

```
x_train, x_test=x_train. reshape(num_train, -1), x_test. reshape(num_test, -1)
x_train_square=torch. sum(x_train**2, axis=1, keepdim=True)
x_test_square=torch. sum(x_test**2, axis=1)
cross=torch. matmul(x_train, x_test. T)
dists=torch. sqrt(x_test_square-2*cross+x_train_square)
```

三. 執行結果:

1. 與 two loop 的差異:

Difference: 3.1752595889861834e-13 Good! The distance matrices match

2. 比較每一個 loop 的執行時間,發現 no loop 花的時間比較少。如下圖所示:

Two loop version took 7.23 seconds One loop version took 0.92 seconds (7.8% speedup) No loop version took 0.05 seconds (151.2% speedup)

四. 參考文獻:

https://ljvmiranda921.github.io/notebook/2017/02/09/k-nearest-neighbors/

肆. Predict_label:

一.介紹:先決定 k 的大小,通常是奇數。再從距離矩陣中找出 k 個最小距離和對應的 label,再從這 k 個資料裡頭進行投票,出現次數最多的就是他預測到的 label。

二. 程式說明:

- 1. 用一個 loop for test 數量
- 2. 利用 indices=torch. argsort(dists[:,i])將距離矩陣的 第 i 筆距離由大到小進行參數排列。

- 3. 利用 index=indices[range(k)]把前 k 個最小的距離放到 index 陣列裡面。
- 4. 利用 closest_y=y_train[index]把 index 對應到 y_train 的 label。
- 5. 利用 counts=torch. bincount(closest_y)記錄著 label 的出現次數。
- 6. 利用 y_pred[i]=torch.argmax(counts)紀錄出現次數最 多的 label。

7. 程式碼:

三. 執行結果:

伍. knn 利用 class:

class KnnClassifier:

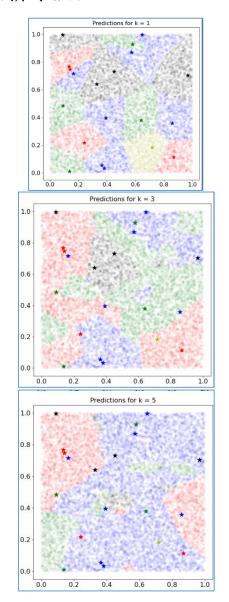
一. __init__:在呼叫 class 時,把 x_train 和 y_train 初始 化,如下圖所示:

二. predict:題目指定要用 no loop 算出距離矩陣,所以算距離矩陣時代入我剛剛寫的 compute_distances_no_loops 的 function裡,預測時代入我剛剛寫的 predict function。完整程式如下:

y_test = classifier.predict(x_test, k=k)

三. 執行結果:

1. 不同的 k 預測出來的結果:可以看出 k 的越大,可以與更多人參與投票,有機會把原本可能會猜錯的給預測正確。 K 比較小時可能會因為雜訊而預測錯誤



2. k=1 時的準確率:

```
from knn import KnnClassifier

torch.manual_seed(0)
num_train = 5000
num_test = 5000
x_train, y_train, x_test, y_test = data.cifar10(num_train, num_test)

classifier = KnnClassifier(x_train, y_train)
classifier.check_accuracy(x_test, y_test, k=1)

Got 137 / 500 correct: accuracy is 27.40%
27.4
```

3. k=5 時的準確率:

```
from knn import KnnClassifier

torch.manual_seed(0)
num_train = 5000
num_test = 500
x_train, y_train, x_test, y_test = data.cifar10(num_train, num_test)

classifier = KnnClassifier(x_train, y_train)
classifier.check_accuracy(x_test, y_test, k=5)

Got 139 / 500 correct: accuracy is 27.80%
27.8
```

伍. Cross-validation:

一.介紹:把資料放入 F 個資料夾中,將其中 F-1 份的資料當作 訓練集,剩下來的那份做為驗證集,算出準確率,再從沒當過驗證 集的資料挑一份出來當驗證集,如此反覆直到每一份資料都當過驗 證集,總共會執行 F 次,算出 F 個準確率。如下圖所示:

二. 程式說明:

fold 1	fold 2	fold 3	fold 4	fold 5	test
fold 1	fold 2	fold 3	fold 4	fold 5	test
fold 1	fold 2	fold 3	fold 4	fold 5	test

1. 利用 torch. chunk 把資料放入 num_folds 個資料夾,如下

圖所示:

x_train_folds=torch.chunk(x_train, num_folds)
y_train_folds=torch.chunk(y_train, num_folds)

2. 題目要求我們在多個 k 底下評估準確率,所以先有一個 for k-list 的 for loop, 並把各個 k 的準確率用字典存起來,如下 圖所示:

3. for 裡面在放一個 for loop 用來做 num_folds 次交叉驗證,如下圖所示:

4. 把 train_folads 的第 fold 筆資料夾當作驗證集存起來, 如下圖所示:

5. 把不是驗證集的資料夾用 torch. cat 串起來,如下圖所

示:

```
x_train_flod_4=torch.cat(x_train_folds[:flod]+x_train_folds[flod+1:], dim=0)
y_train_flod_4=torch.cat(y_train_folds[:flod]+y_train_folds[flod+1:], dim=0)
```

6. 把剛剛的 train data 丟到 model 裡訓練,再把驗證集丟 到模型裡預測,如下圖所示:

classifier=KnnClassifier(x_train_flod_4, y_train_flod_4)
y_val_pred=classifier.predict(x_val, k=k_num)

7. 計算剛剛預測出來的準確率,並把結果存入字典裡。如下

圖所示:

```
num_correct=torch.sum(y_val_pred=y_val)
accuracy=float(num_correct)/y_val.shape[0]
k_to_accuracies[k_num].append(accuracy)
```

8. 完整程式碼:

x_train_folds=torch.chunk(x_train, num_folds)
y_train_folds=torch.chunk(y_train, num_folds)

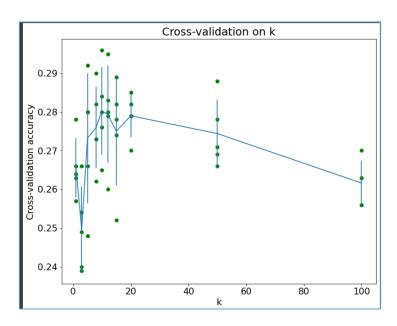
```
for k_num in (k_choices):
    k_to_accuracies[k_num]=[]
    for flod in range(num_folds):
        x_val=x_train_folds[flod]
        y_val=y_train_folds[flod]
        x_train_flod_4=torch.cat(x_train_folds[:flod]+x_train_folds[flod+1:], dim=0)
        y_train_flod_4=torch.cat(y_train_folds[:flod]+y_train_folds[flod+1:], dim=0)
        classifier=KnnClassifier(x_train_flod_4, y_train_flod_4)
        y_val_pred=classifier.predict(x_val, k=k_num)
        num_correct=torch.sum(y_val_pred==y_val)
        accuracy=float(num_correct)/y_val.shape[0]
        k_to_accuracies[k_num].append(accuracy)
```

三. 執行結果:

1. 每個字典裡的資料:

```
k = 1 got accuracies: [0.263, 0.257, 0.264, 0.278, 0.266]
k = 3 got accuracies: [0.239, 0.249, 0.24, 0.266, 0.254]
k = 5 got accuracies: [0.248, 0.266, 0.28, 0.292, 0.28]
k = 8 got accuracies: [0.262, 0.282, 0.273, 0.29, 0.273]
k = 10 got accuracies: [0.265, 0.296, 0.276, 0.284, 0.28]
k = 12 got accuracies: [0.26, 0.295, 0.279, 0.283, 0.28]
k = 15 got accuracies: [0.252, 0.289, 0.278, 0.282, 0.274]
k = 20 got accuracies: [0.27, 0.279, 0.279, 0.282, 0.285]
k = 50 got accuracies: [0.271, 0.288, 0.278, 0.269, 0.266]
k = 100 got accuracies: [0.256, 0.27, 0.263, 0.256, 0.263]
```

2. 資料分布和 errorbar,可大約看到最佳 k 在 0-20 之間:



四. 參考資料:

https://scikit-

learn.org/stable/modules/cross_validation.html

陸. knn_best_k:

一.介紹:剛剛做完 cross_validation 之後,我們再將這幾個資料夾裡的準確率取平均,用平均分數來評斷模型的好壞,再從多個 k 中取出準確率最高的。

二. 程式碼:

三. 執行結果:

```
from knn import KnnClassifier
from knn import knn_get_best_k

best_k = 1
torch.manual_seed(0)

best_k = knn_get_best_k(k_to_accuracies)
print('Best k is ', best_k)

classifier = KnnClassifier(x_train, y_train)
classifier.check_accuracy(x_test, y_test, k=best_k)

Best k is 10
Got 141 / 500 correct: accuracy is 28.20%
28.2
```

柒. Run cifar-10 full data to get accuracy from best k:

一. 執行結果:

```
from knn import KnnClassifier

torch.manual_seed(0)

x_train_all, y_train_all, x_test_all, y_test_all = data.cifar10()

classifier = KnnClassifier(x_train_all, y_train_all)

classifier.check_accuracy(x_test_all, y_test_all, k=best_k)

Got 3386 / 10000 correct; accuracy is 33.86%

33.86
```